



Mariana Perna

# MP&E

Aleatório: acontecimento cujo resultado não possa ser determinado com certeza absoluta. Diz-se de uma grandeza que pode tomar certo número de valores, a cada um dos quais está ligada uma probabilidade.

No entanto, na maioria das aplicações existe algum tipo de regularidade que se manifesta se o número de observações/experiências for elevado

Alide 5

0 1 2 3 4 5 6 7 8 9

$$\overline{\quad} \quad \overline{\quad} \quad \overline{\quad} \quad \overline{\quad}$$
$$10 \times 10 \times 10 \times 10$$

a)  $P = \frac{1}{10000}$

b)  $P = \frac{1}{10^{20}}$

- espaço de amostragem
- conjunto de acontecimentos
- lei da probabilidade

Experiência  
Aleatória

 é  
associado

procedimento que deve produzir um resultado mas com um resultado imprevisível e diferente

**Espaço de amostragem:** é o conjunto de todos os resultados possíveis de uma experiência aleatória. (S) Elementos desse conjunto são considerados resultados elementares.

- S constitui o evento certo (1)
- Ø (conjunto vazio) representa o evento impossível (0)

A **lei de probabilidade** atribui probabilidade aos vários eventos.

**PROBABILIDADE:** número associado a um evento que indica a "verosimilhança" de esse evento ocorrer quando se efetua a experiência. Valor entre 0 e 1.

Como se obtém as probabilidades associadas a eventos?

Há diferentes abordagens:

- **Teoria clássica (de Laplace)** probabilidades teóricas

$$P(\text{evento}) = \frac{\text{nº de casos favoráveis}}{\text{nº de casos possíveis}}$$

REGRAS:  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

↓  
equiprobabilidade  $P(\bar{A}) = 1 - P(A)$

para os  
eventos  
elementares

$P(A \cap B) = P(A) \times P(B)$  só para Acontecimentos Independentes

## Slide 25

família com 2 filhos

- nascimento de um menino, M
- nascimento de uma menina, F

Qual é a probabilidade de haver pelo menos um rapaz numa família com 2 filhos?

casos possíveis

- MM
- MF
- FM
- FF

casos favoráveis

- MM
- MF
- FM

$$P(\text{pedida}) = \frac{3}{4}$$

• Abordagem frequencista

Simples  
mas não  
perfeita

Repete-se a experiência um certo número de vezes ( $N$ ).  
Seja  $K$  o número de vezes que ocorre o acontecimento que nos interessa. Determina-se a frequência relativa de ocorrência ,  $f = \frac{K}{N}$

↓  
medida empírica de probabilidade

## Frequência Relativa

• Se uma experiência for repetida  $N$  vezes nas mesmas condições a frequência relativa do evento A é

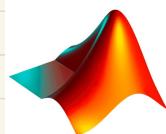
$$f(A) = \frac{\text{nº de ocorrências do evento A}}{N}$$

$$0 \leq f(A) \leq 1$$

• Se a frequência relativa convergir quando  $N$  aumentar, então o limite da frequência relativa é a probabilidade de  $A$ .

$$p(A) = \lim_{N \rightarrow +\infty} \frac{\text{nº de ocorrências de } A}{N}$$

probabilidade  
do evento  $A$  ocorrer



exemplo  
em

MATLAB®

Probabilidade  
de sair 2  
caras em 3  
lançamentos

% Simular os 3 lançamentos

$$\text{lan\_3} = \text{rand}(3,1) < 0,5$$

% repetir  $N$  vezes

$$N = 1e6$$

$$\text{lancamentos} = \text{rand}(3,N);$$

cria uma matriz  $3 \times N$  de valores  
aleatórios entre 0 e 1  
cada coluna representa um ensaio

% contar o número de ocorrências de "2 caras"

% contar o número de caras (1's) em cada experiência

$$\text{numCarasExperiencia} = \text{sum}(\text{lancamentos});$$

% contar vezes em que esse número de caras é 2

$$\text{numOcorrencias} = \text{sum}(\text{numCarasNaExperiencia} == 2)$$

% calcular a frequência relativa

$$fr = \text{numOcorrencias}/N$$

% usar como estimativa da probabilidade

$$pA = fr$$

# Problema de aprovações a MPEI

## Simulação em MATLAB

```
p = 0.85; % prob aproximada de aluno aprovado passar  
n = 165; % n.º de alunos de MPEI  
N = 1e6; % n.º de experiências  
K = fix(0.8*n); % 80% dos alunos  
% remove a vírgula flutuante, arredondando os números imprecisamente
```

```
aprovados = rand(n,N) < p; % 1 indica a aprovação do aluno
```

```
numOcorrencias = 0;
```

```
for K1 = K:n
```

```
succesos = sum(aprovados) == K1;
```

```
fprintf('%d aprovados ->%8d, p=%.5f\n', K1, sum(succesos), sum(succesos)/N);  
numOcorrencias = numOcorrencias + sum(succesos);
```

```
end
```

```
probSimulacao = numOcorrencias/N;
```

```
fprintf('prob de %d ou mais em %d passarem é de %f\n', K, n, probSimulacao);
```

prob de 132 ou mais em 165 passarem é de 0.98

## • Teoria Axiomática de Probabilidade

com base nas propriedades das frequências relativas e das operações sobre conjuntos

## O que é uma axiomática?

Em determinado ponto da evolução de uma teoria de pensamento matemático, torna-se imperioso ordenar, sistematizar e relacionar todos os conhecimentos existentes nela reconhecidos, isto é, proceder à sua AXIOMATIZAÇÃO.

**Axioma 1:** probabilidades são não negativas  
 $P(A) \geq 0$

**Axioma 2:** normalização (tem probabilidade 1)  
 $P(S) = 1$

**Axioma 3a:** se  $A$  e  $B$  forem mutuamente exclusivos  
 $P(A \cup B) = P(A) + P(B)$

**Axioma 3b:** se  $A_1, A_2, \dots$  for uma sequência infinita de acontecimentos mutuamente exclusivos

$$P\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{i=1}^{\infty} P(A_k)$$

## TEOREMAS

• Probabilidade do acontecimento complementar

$$P(\bar{A}) = 1 - P(A)$$

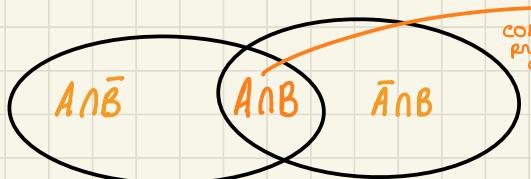
Demonstração: como  $A \cap \bar{A} = \emptyset$  e  $A \cup \bar{A} = S$

pelos axiomas 2 e 3  $P(A \cup \bar{A}) = P(A) + P(\bar{A}) = P(S) \dots$

$$P(A) + P(\bar{A}) = 1$$
$$\Leftrightarrow P(\bar{A}) = 1 - P(A), \text{ c.q.d}$$

• Probabilidade da união

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$



contexto de probabilidade condicionada  
Zona onde A se realiza sabendo que B ocorreu

Demonstração:  $P(A \cup B) = (P(A \bar{B}) + P(AB)) + (P(AB) + P(\bar{A}B)) - P(AB)$   
 $= P(A) + P(B) - P(AB), \text{ c.q.d.}$

• Probabilidade em espaço de amostragem n/contáveis

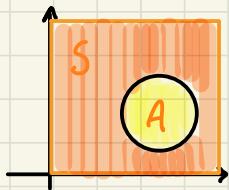
exemplo 1: Escolha de um número real no intervalo  $[a, b]$ .  
 Seja o acontecimento A "número pertencer a  $[c, d]$ "



$$P(A) = \frac{(d - c)}{(b - a)}$$

exemplo 2: No caso de um par de números reais  $x, y$  entre 0 e 1

$$S = \{x, y : x \in [0, 1] \cap y \in [0, 1]\}$$



$$P(A) = \frac{\text{Área}(A)}{\text{Área}(S)}$$

• A axiomática é compatível com a definição frequentista!  
 (PROVADO nos Slides 57, 58 e 59)

• A Axiomatização é compatível com a Lei de La Place!  
 (PROVADO nos Slides 60, 61, 62 e 63)

**NOTA:** complementar usando o condicional

$$P(\neg A | B) + P(A | B) = 1$$

$$P(\neg A | B) = 1 - P(A | B)$$

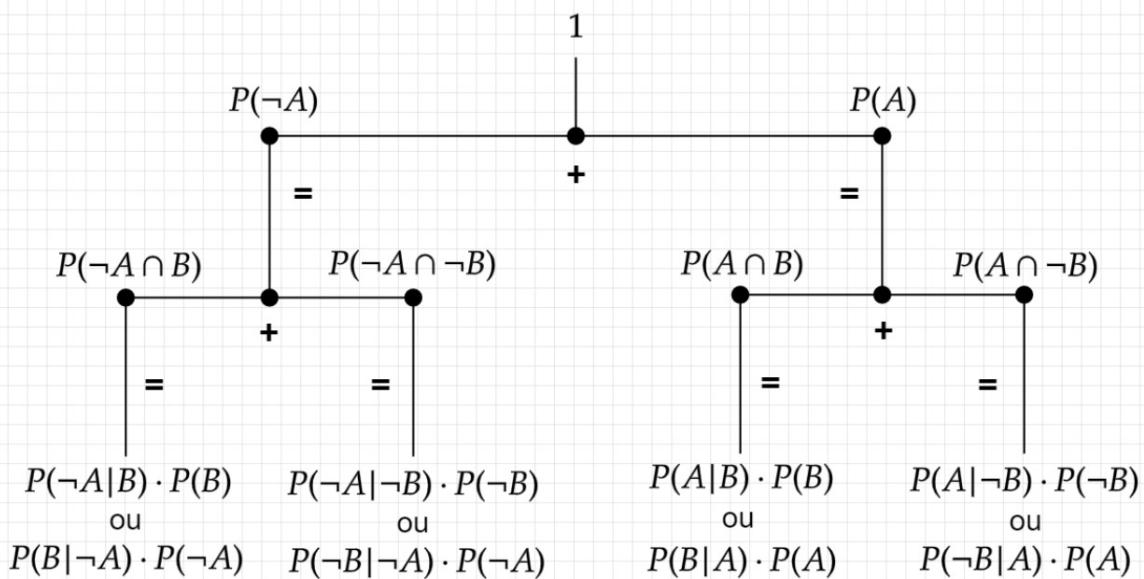
# Probabilidade condicional

↳ quando dois acontecimentos estão relacionados. A ocorrência de um depende ou jáz depender a ocorrência do outro.

$$P(A|B) = \frac{P(AB)}{P(B)} \text{ se } P(B) \neq 0$$

## Cadeia condicional da probabilidade

é a possibilidade de dividir a probabilidade de um evento usando a probabilidade condicional



Podemos decompor a probabilidade de acordo com sua condicional

$$P(\neg A) = P(\neg A \cap B) + P(\neg A \cap \neg B)$$

$$P(A) = P(A \cap B) + P(A \cap \neg B)$$

$$1 = P(\neg A) + P(A)$$

$$P(A \cap B) = P(A|B) \times P(B)$$

$$P(A \cap B \cap C) = P(A) \times P(B|A) \times P(C|A \cap B)$$

## Lei da probabilidade total

- dividir para conquistar
- partição do espaço de amostragem  $A_1, A_2, A_3$
- ter  $P(B|A_i)$ , para todos os i

$$P(B) = \sum_j P(B|A_j) P(A_j)$$

## Condicionamento inverso

↳ Simplemente pensar no problema inverso

## Regra de Bayes

A ideia principal do Teorema de Bayes é inverter as probabilidades condicionais. Por exemplo, queremos saber a probabilidade  $P(X|Y)$  mas conhecemos apenas a probabilidade de  $P(Y|X)$ .

Antes, vamos reescrever a nossa fórmula da probabilidade condicional para utilizarmos de uma forma melhor. Vamos passar o denominador multiplicando para o outro lado da equação:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \Leftrightarrow P(A|B) \cdot P(B) = P(A \cap B)$$

e também

$$\updownarrow P(A \cap B) = P(B \cap A)$$

$$P(B|A) = \frac{P(B \cap A)}{P(A)} \Leftrightarrow P(B|A) \cdot P(A) = P(B \cap A)$$

então podemos concluir que:

$$P(B \cap A) = P(A \cap B) = P(B|A) \cdot P(A) = P(A|B) \cdot P(B)$$

Variação da regra da probabilidade condicional

montando o Teorema de Bayes  
sabendo que

$$\bullet P(A \cap B) = P(B|A) \cdot P(A) \quad \bullet P(A|B) = \frac{P(A \cap B)}{P(B)}$$

e assim obtemos o Teorema de Bayes

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Vamos a um típico problema que o Teorema de Bayes é usado: Uma certa doença afeta 1 a cada 10,000 pessoas. Existe um teste para verificar se a pessoa possui a doença ou não.

Desse problema sabemos que:

- A probabilidade do teste dar **positivo**, dado que a pessoa **não tem a doença** é de 2%.
- A probabilidade do teste dar **negativo**, dado que a pessoa **possui a doença** é de apenas 1%.

Se uma pessoa aleatória fizer o teste da doença e der positivo, qual é a probabilidade de que a pessoa tenha a doença?

Vamos dizer que  $D$  é o evento em que a pessoa tem a doença, e que  $T$  seja o evento em que o teste tenha dado positivo. Logo queremos descobrir  $P(D|T)$ .

Sabemos

$$\cdot P(D) = 0,0001 \quad \cdot P(T|\neg D) = 0,02 \quad \cdot P(\neg T|D) = 0,01$$

$$\begin{aligned} P(D \cap T) &= P(D|T) \cdot P(T) \\ &= P(T|D) \cdot P(D) \\ &= (1 - P(\neg T|D)) \cdot P(D) \\ &= (1 - 0,01) \cdot 0,0001 \\ &= 0,000099 \end{aligned}$$

$$\begin{aligned} P(T) &= P(T \cap D) + P(T \cap \neg D) \\ &= (P(T|D) \cdot P(D)) + (P(T|\neg D) \cdot P(\neg D)) \\ &= ((1 - P(\neg T|D)) \cdot P(D)) + (P(T|\neg D) \cdot P(\neg D)) \\ &= ((1 - 0,1) \cdot 0,0001) + (0,02) \cdot 0,9999 \\ &= 0,020097 \end{aligned}$$

$$P(D|T) = \frac{P(D \cap T)}{P(T)} = \frac{0,000099}{0,020097} \approx 0,0049$$

# Independência

dois acontecimentos são independentes se e só se

$$P(A \cap B) = P(A) \cdot P(B)$$

implica  $P(A|B) = P(A)$

aplica-se mesmo que  $P(A) = 0$

ocorrência de B não fornece informação sobre ocorrência de A

**Experiências de Bernoulli** consiste em realizar uma experiência e registrar se um dado acontecimento se verifica (sucesso) ou não (falha).

Qual a probabilidade de  $K$  sucessos em  $n$  ensaios independentes?

- Seja  $p$  a probabilidade de sucesso e  $(1-p)$  a de falha
- a probabilidade de  $K$  sucessos e  $(n-K)$  falhas é:  
$$p^K (1-p)^{n-K}$$
- $K$  sucessos em  $n$  experiências podem ocorrer  $C_K^n$  maneiras

então a probabilidade pedida é:

$$P_n(K) = C_K^n p^K (1-p)^{n-K}$$

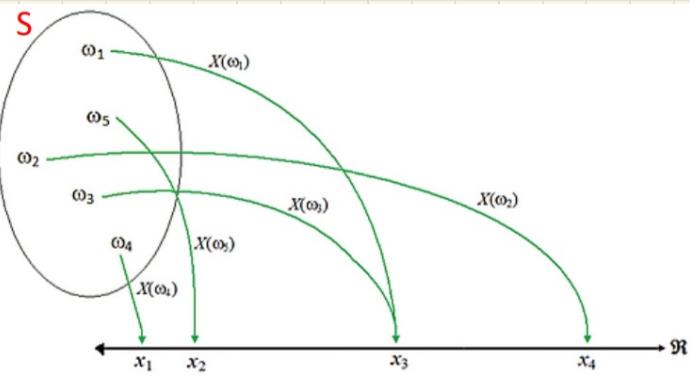
Lei  
Binomial

# Variáveis aleatórias

Uma **variável aleatória** é uma função que mapeia o espaço de amostragem na reta real. Por outras palavras, é o resultado numérico das nossas experiências aleatórias.

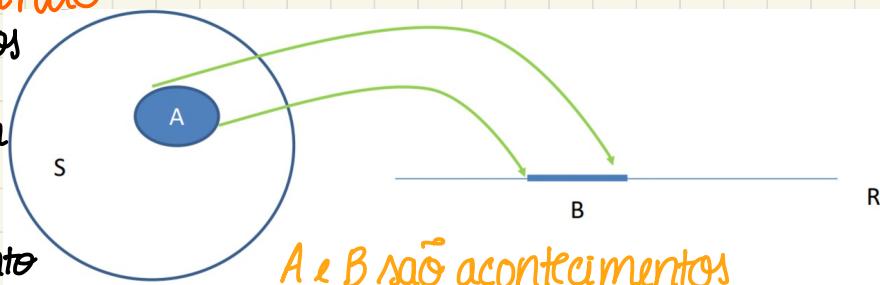
**DEFINIÇÃO:** Uma variável aleatória escalar  $X$  é formalmente definida como sendo um mapeamento de um espaço amostral  $S$  para a reta real.

a qq elemento  $\omega$  de  $S$  associa-se uma imagem  $X(\omega)$  na reta real



## Caso contínuo

Se os conjuntos que representam os eventos forem contínuos, o mapeamento é para um segmento da reta real



$A \in B$  são acontecimentos equivalentes

## Tipos de variáveis aleatórias:

- **Discreta**, se os valores que a variável aleatória pode assumir forem finitos (ou infinitos mas contáveis, por exemplo: o nº de acessos por minuto a uma página web);

- continua , se os valores que pode assumir formarem um ou vários intervalos disjuntos, por exemplo a duração de uma aula no zoom;

- mista , onde se verificam os atributos que definem os 2 tipos anteriores.

# Caracterização das variáveis aleatórias

PARTE 1

## • Distribuição de probabilidades

as variáveis aleatórias são caracterizadas pelo conjunto de valores que podem assumir e as probabilidades associadas

## • Função (massa) de probabilidade

Uma variável aleatória discreta escalar  $X$  é especificada por:

1. conjunto de valores que pode assumir  $\{n_i, i = 1, 2, \dots\}$

2. probabilidade associada a cada um desses valores  $p_n(n_i)$

$$p_n(n_i) = P(X = n_i) = P(w: X(w) = n_i)$$

AXIOMAS:  $p_n(n_i) \geq 0$

$$\sum_i p_n(n_i) = 1$$

$\downarrow$   
denominada  
função massa de  
probabilidade

EXEMPLO: Lançamento de um dado equilibrado e  $X$  igual ao nº que sai

$X$ : variável aleatória discreta

função de probabilidade:  $n_i = \{1, 2, 3, 4, 5, 6\}$

$$p_n(n_i) = \frac{1}{6}$$

%% Matlab

$n_i = 1:6$ ;  $p = ones(1,6)/6$ ;  
 $stem(ni, p)$ ;  $xlabel('n')$ ;  $ylabel('p_n(n)')$ ;

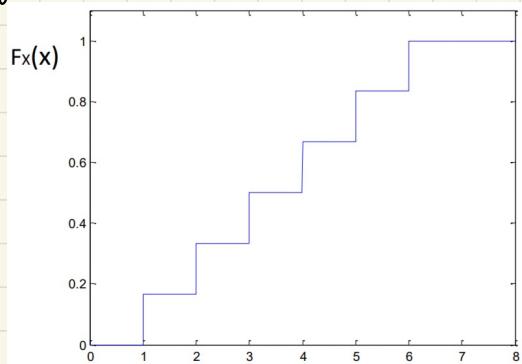
# Função distribuição acumulada (discreta), fda

$$F_n(x) = P(X \leq n) = \sum_{i: n_i \leq n} p_n(n_i)$$

↓ é uma função não decrescente

- $\lim_{n \rightarrow -\infty} F_n(x) = 0$
- $\lim_{n \rightarrow \infty} F_n(x) = 1$

**EXEMPLO:** Para uma variável aleatória discreta a função distribuição acumulada é uma função em escada.



## Variáveis aleatórias contínuas

Tb pode ser especificada pela sua função distribuição acumulada

$$F_n(x) = \text{Prob}(X \leq n)$$

**PROPRIEDADES:**  $0 \leq F_n(x) \leq 1$

$$\lim_{n \rightarrow \infty} F_n(x) = 1$$

$$a < b \Rightarrow F_n(a) \leq F_n(b)$$

$$\lim_{n \rightarrow -\infty} F_n(x) = 0$$

$$P[a < X \leq b] = F_n(b) - F_n(a)$$

Tb podem ser especificadas pela sua função de densidade de probabilidade

$$\frac{\text{prob}}{dx} \equiv f_n(x) = \frac{d F_n(x)}{dx}$$

Não é uma probabilidade, apenas define os valores de probabilidade quando integrada num intervalo

obtém-se derivando a função de distribuição

$$P(a < X \leq b) = F_n(b) - F_n(a) = \int_a^b f_n(x) dx$$

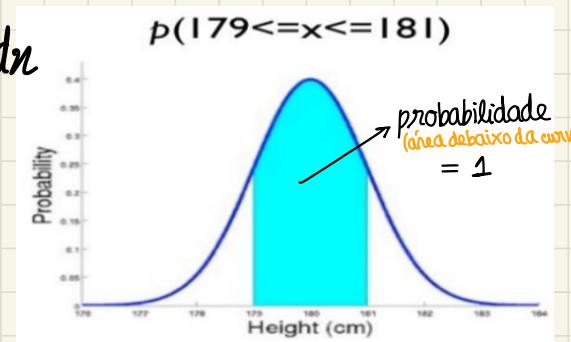
é a probabilidade da variável x pertencer ao intervalo  $[n, n+dx]$ , sendo dx um desígnio infinitesimal

Relações entre funções de densidade e de distribuição (caso contínuo)

$$F_n(x) = \int_{-\infty}^x f_n(u) du$$

Probabilidades e função de densidade

$$P(a < X \leq b) = \int_a^b f_n(u) du$$



Caracterização das variáveis aleatórias

PARTE 2

em muitos casos não necessitamos de toda a informação. No caso dos "bugs" em módulos de código saber o valor médio pode ser suficiente !!!

consideremos N lançamentos de um dado

Média:  $\frac{\text{numDe } 1S}{N} \times 1 + \frac{\text{numDe } 2S}{N} \times 2 + \dots + \frac{\text{numDe } 6S}{N} \times 6$

Assumindo que N tende para infinito

$$\text{Média} = p(1) \times 1 + p(2) \times 2 + p(3) \times 3 + \dots + p(6) \times 6 \\ = \sum_i p(n_i) n_i \quad c/ \quad n_i = 1, 2, \dots, 6$$

## Valor esperado

mas não é algo que devemos esperar que aconteça...

Consideremos as experiências na origem da variável aleatória X:  
assim

O valor esperado de X é o valor médio de X ao repetirmos as  
experiências indefinidamente

$$\lim_{n \rightarrow \infty} \frac{X_1 + X_2 + \dots + X_n}{n}$$

Se existe valor esperado  
se existir o limite  
(o limite existe se  $x_i$  tiver limite inferior e superior finitos)

$x_i$  é o valor de x na experiência i

Representando por  $n_i$ : os m diferentes valores que  $X_i$  pode assumir e por  $k_{i,n}$  o número de vezes que ocorre cada  $n_i$ :

$$\lim_{n \rightarrow \infty} \frac{n_1 k_{1,n} + n_2 k_{2,n} + \dots + n_m k_{m,n}}{n}$$

$$\sum_{i=1}^m n_i \lim_{n \rightarrow \infty} \frac{k_{i,n}}{n} = \sum_{i=1}^m n_i P(X = n_i)$$

### PROPRIEDADES:

como  $E[x]$  é um operador linear  
então:

- $E[aX] = aE[X]$
- $E[X+Y] = E[X] + E[Y]$
- $E[X+c] = E[X] + c$

O Valor esperado de uma variável designa-se por  $E(X)$

• no caso DISCRETO  $E[X] = \sum_i n_i p(n_i)$

• no caso CONTÍNUO  $E[X] = \int_{-\infty}^{+\infty} x f_x(x) dx$

## a Média pode não ser suficiente

Por exemplo, se pretendermos comparar as classificações de duas turmas práticas de MPE, posso ter a mesma média e ter turmas muito diferentes.

Uma medida dessa "dispersão" é dada pela Variância.

ideia base

usar a diferença dos valores da variável para a média (valor esperado) e fazer a sua média e para evitar nº negativos, usaremos o seu valor quadrático

$$\begin{aligned} \text{Var}(x) &= E[(x - E(x))^2] \\ &= \sigma^2 \\ &= \sum_i [x_i - E(x)]^2 p(x_i) \end{aligned}$$

PROPRIEDADE

$$\text{Var}(x) = E[x^2] - E^2[x]$$

X = variável aleatória; c = constante

$$\text{Var}(x+c) = \text{Var}(x)$$

$$\text{Var}(cx) = c^2 \text{Var}(x)$$

## Desvio padrão

, raiz quadrada da variância ( $\sigma$ )

## Interpretação:

### - Média ou valor esperado

$E(x)$  pode ser interpretado como:

- valor médio de X

- Centro de gravidade da função massa de probabilidade (caso discreto) ou função de densidade de probabilidade

### - Desvio padrão / variância

Dá uma medida da dispersão da variável aleatória

- pequenos valores indicam variável aleatória muito concentrada em torno da média (sejor não temos variável aleatória, todos os valores são iguais à média).

Momento de ordem  $n$  (caso discreto)

$$m_n = E[X^n] = \sum n_i^n p_n(n_i)$$

Momento centrado de ordem  $n$  (resulta da generalização da variância)

$$E[(X - E(X))^n] = \sum_i (n_i - E[X])^n p_n(n_i)$$

A variância é o momento centrado de 2ª ordem

## Variáveis aleatórias - DISTRIBUIÇÕES

As funções de massa de probabilidade e de densidade de probabilidade podem assumir as mais variadas formas. Mas existe um conjunto de "formas" (distribuições) que aparecem repetidamente em mts problemas

### Discretas

- Bernoulli
- Binomial
- Poisson
- Geométrica
- [...]

### Contínuas

- Uniforme
- Normal
- Exponencial
- [...]

## Distribuições Discretas

### • Distribuição de Bernoulli

(dirutamente relacionada c/ as experiências de Bernoulli)

Seja  $A$  um acontecimento relacionado c/ o resultado de uma experiência aleatória. A variável de Bernoulli define-se como

$$I_A(W) = \begin{cases} 1 & se W \in A \\ 0 & caso contrário \end{cases}$$

qd o evento ocorre a variável aleatória I assume o valor 1, caso contrário o valor 0

espaço de amostragem

$$S_I = \{0, 1\}$$

$$p = P_I(A)$$

$$\cdot P_I(1) = p$$

$$\cdot P_I(0) = 1 - p$$

$$E[I^2] = 0^2 \times (1-p) + 1^2 \times p = p$$

$$E(I) = \sum_i n_i p(n_i)$$

$$= 0 \times (1-p) + 1 \times p$$

$$= p$$

$$Var(I) = E[I^2] - (E[I])^2$$

$$= p - p^2$$

$$= p(1-p)$$

## Distribuição Binomial

(diretamente relacionada c/ a Lei Binomial)

Seja  $X$  o número de vezes que um acontecimento A ocorre em  $n$  experiências de Bernoulli, isto é,  $X$  representa o nº de sucessos em  $n$  experiências (observações)

$$X = \sum_{j=1}^n I_j \rightarrow S_X = \{0, 1, 2, \dots, n\}$$

espaço de amostragem

- $P_n(k) = P_n(X=k) = \binom{n}{k} p^k (1-p)^{n-k}$

- $F_n(n) = \sum_{k=0}^{[n]} \binom{n}{k} p^k (1-p)^{n-k}$

- $E[X] = np$

- $Var(X) = np(1-p)$

Têm distribuição Binomial, p.ex.:

- nº de peças defeituosas num lote de um determinado tamanho

- nº de respostas certas num exame de V/F

- nº de clientes que efetuam compras em 100 que entram numa loja

## exemplo de aplicação 2: segurança e aviões

- $P$ , probabilidade de falhar
- um avião cai se + de 50% dos motores falham

avião de 4 motores

(este avião despenha-se qd 3 ou 4 motores falhem)

$$\begin{aligned} p_4 &= p_x(3, n=4) + p_x(4, n=4) \\ &= \binom{4}{3} p^3 (1-p)^{4-3} + \binom{4}{4} p^4 (1-p)^{4-4} \\ &= 4p^3 - 3p^4 \end{aligned}$$

avião de 2 motores

(este avião despenha-se qd 2 motores falham)

$$\begin{aligned} p_2 &= p_x(2, n=2) \\ &= \binom{2}{2} p^2 (1-p)^{2-2} \\ &= p^2 \end{aligned}$$

Relação entre  $p_2$  e  $p_4$

$$\frac{p_4}{p_2} = 4p - 3p^2 = p(4 - 3p) \quad \text{depende de } p //$$

tentar para valores de  $p$

## Distribuição geométrica

Seja  $X$  o nº de vezes que é necessário repetir uma experiência de Bernoulli até obter um sucesso

prob. sucesso =  $p$

prob. falha =  $1-p$

- $p_n(k) = p(1-p)^{k-1}$ ,  $k = 1, 2, 3, \dots$  pq teremos  $k-1$  insucessos e depois sucesso
- $F_n(n) = \sum_{k=0}^{[n]} p(1-p)^{k-1}$

**exemplo:** Supondo que a probabilidade de conseguir contactar o suporte é  $p = 0,1$  (só ao fim de 10 tentativas). Determine a probabilidade de necessitar de menos de 3 chamadas até conseguir expo o seu problema.

$$\begin{aligned} P_{\geq 2}(n \text{ chamadas} < 3) &= P_{\geq 1}(1 \text{ chamada} \vee 2 \text{ chamadas}) \\ &= p[1-p]^{1-1} + p[1-p]^{2-1} \\ &= 0,1(1-0,1)^0 + 0,1(1-0,1)^1 \\ &= 0,19 \end{aligned}$$

qt + provável atenderem  
- chamadas teremos que fazer  
(em média)

- $E[X] = \frac{1}{p}$
- $\text{Var}(X) = \frac{(1-p)}{p^2}$

## Distribuição de Poisson

Considere-se que temos uma variável Binomial,  $n$  cresce e  $p$  diminui por forma a  $np \rightarrow \lambda > 0$

para  $n$  grande pode fazer-se as seguintes aproximações:

$$\begin{aligned} \bullet p \cong \frac{\lambda}{n} &\quad \bullet 1-p \cong 1 - \frac{\lambda}{n} \\ \bullet p_n(k) = \frac{\lambda^k e^{-\lambda}}{k!} &= P_{\geq 1}(X=k) \quad , \text{ tem apenas um parâmetro, } \lambda \end{aligned}$$

$$\bullet E[x] = \lambda$$

→ é aproximadamente  $np$

$$\bullet \text{Var}(x) = \lambda$$

A distribuição de Poisson foca-se apenas no nº de ocorrências (discreto) num intervalo de tempo contínuo (ou região do espaço)

Esta distribuição não tem um número de experiências ( $n$ ) como na Binomial

As ocorrências são independentes das outras ocorrências

### Aproximação de Poisson à distribuição Binomial

Problemas envolvendo a distribuição Binomial em que  $n$  é grande e o valor de  $p$  é pequeno, gerando desta forma eventos raros, não os candidatos à utilização da distribuição de Poisson

**REGRA:** Se  $n > 20$  e  $np \leq 7$  a aproximação de Poisson é suficientemente próxima para ser usada em vez da Binomial

### PROCEDIMENTO:

1. Calcular a média da Binomial  $\mu = np$ ;

2. Como  $\mu$  é o valor esperado da Binomial, passa a ser o  $\lambda$  ( $= E[x]$ ) de Poisson

3. Usar a fórmula de Poisson

$$P_n(k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

exemplos da aplicação da distribuição de Poisson:  
• o nº de resultados que ocorrem num determinado intervalo de tempo ou região é independente do nº que ocorre em q'q' outro intervalo temporal ou regiões espacial disjuntas;

• a probabilidade que um resultado ocorra durante um intervalo ou região infinitesimal é proporcional ao comprimento do intervalo ou dimensão da região e não depende das ocorrências fora desse intervalo ou região;

• a probabilidade de haver mais que um resultado numa região infinitesimal é desprezável;

# Distribuições contínuas

## • Distribuição uniforme

$U(a,b)$  é definida por:

$$\bullet f_X(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{caso contrário} \end{cases}$$

$$\bullet F_X(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \end{cases}$$

$$\bullet E[X] = \frac{a+b}{2}$$

$$\bullet \text{Var}(x) = \frac{(b-a)^2}{12}$$

EXEMPLO:

$$P(42 \leq X \leq 45) \text{ com } U(41,47)$$

$$\begin{aligned} P(x_1 \leq X \leq x_2) &= \\ &= \frac{x_2 - x_1}{b-a} \end{aligned}$$

A Função `rand()` do Matlab gera números obedecendo a uma distribuição uniforme

com  $a=0$  e  $b=1$  então

$$U(a,b) = a + \text{rand}() * (b-a)$$

## • Distribuição Normal (ou Gaussiana)

$$\bullet f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-m)^2}{2\sigma^2}}$$

• notação:  $N(m, \sigma^2)$

• curva em forma de sino, simétrica em torno da média ( $m$ ) e com alongamento  $\sigma$

$$\bullet F_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-m)^2}{2\sigma^2}} dt$$

- $E[x] = m$
- $\text{Var}(x) = \sigma^2$

é mais comum utilizar-se  $\mu$  em vez de  $m$  para representar a média

## Gaussianas normalizadas

Como existe um n.º infinito de combinações para  $m$  e  $\sigma$  pode gerar-nos uma família infinita de curvas

↓ então

Foi desenvolvido um mecanismo pelo qual qualquer distribuição normal pode ser convertida numa distribuição única, a Gaussianas normalizada  $N(0,1)$ .

A fórmula de conversão é:

$$Z = \frac{x - m}{\sigma}$$

, subtrair a média e dividir pelo desvio padrão

### • Função densidade de probabilidade

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x)^2}{2}}$$

### • Função de distribuição acumulada

*valor tabelado*

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(t)^2}{2}} dt$$

$$F_x(x) = \Phi\left(\frac{x - m}{\sigma}\right)$$

A distribuição normal adequa-se / ajusta-se a mts características humanas e a mts outras coisas da natureza. Surge quando vários efeitos acumulados e independentes se sobrepõem.

**Função massa de probabilidade da Binomial**  
de média  $m = np$  e  $\sigma^2 = np(1-p)$  com  $m$  não muito pequeno e  $n$  elevado pode ser aproximado por:

$$f_x(n) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(n-m)^2}{2\sigma^2}}, \text{ ou seja a distribuição normal}$$

desde que  $m = np$  e  
 $\text{Var}(x) = np(1-p)$

## • Distribuição exponencial

→ é não negativa;

→ surge em exercícios envolvendo filas de espera e fiabilidade  
 - tempo até um PC avariar  
 - tempo entre chegada de utentes às urgências

→ está relacionada c/ a distribuição (discreta) de Poisson

(se o n' de acontecimentos que ocorre num intervalo seguem distribuição de Poisson, o tempo entre eles segue distribuição exponencial)

- $f_x(n) = \begin{cases} 0 & , n < 0 \\ \lambda e^{-\lambda n} & , n \geq 0 \end{cases}$

- $F_x(x) = \begin{cases} 0 & , n < 0 \\ 1 - e^{-\lambda n} & , n \geq 0 \end{cases}$

- $E(X) = \frac{1}{\lambda}$
- $\text{Var}(X) = \frac{1}{\lambda^2}$

### Exemplo de aplicação:

A vida útil, em milhares de horas, de um componente de um robô é uma variável aleatória com distribuição exponencial de valor médio 10 (milhares de horas).

Qual a probabilidade de um desses componentes selecionado ao acaso durar menos de 4000 horas?

$$\lambda = \frac{1}{10} = 0,1 \quad P(X < 4) = \int_0^4 0,1 e^{-0,1x} dx \\ = 0,33$$

### Distribuição dos primeiros dígitos (Distribuição de Benford)

função de probabilidade

$$P(d) = \log_{10}(d+1) - \log_{10}(d) \\ = \log_{10}\left(\frac{d+1}{d}\right) \\ = \log_{10}\left(1 + \frac{1}{d}\right)$$

## • Distribuição de Zipf

A lei de Zipf prevê que num dado texto, a probabilidade de ocorrência  $p(n)$  de uma palavra esteja ligada à sua ordem  $n$  na ordem das frequências por uma lei da forma:

$$p(n) = \frac{K}{n} \rightarrow K \text{ é uma constante dependente da língua}$$

$p(n)$  é estimada e/  
base na contagem de  
ocorrências de palavras  
num texto ou conjunto  
de textos